UNIDAD 3 · ACTIVIDAD 3

Transferencia de aprendizaje para reconocer gestos

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12

Notebook y código: Abrir la actividad 3 en el repositorio público de GitHub.

1. Problema y alcance

Clasificamos una imagen de mano en papel, piedra o tijera. Elegimos este problema porque permite evaluar una red preentrenada con pocos datos y analizar si el ajuste fino mejora el modelo con la base congelada. Nuestro alcance es una mano visible, centrada y con un fondo semejante al conjunto de entrenamiento; no planteamos un detector general de manos.

> **Resultado principal.** La base congelada y el ajuste fino lograron 437 aciertos de 437 imágenes de prueba en las tres semillas. Esa igualdad no demuestra una mejora por ajuste fino. Al cambiar a imágenes sintéticas, la exactitud media cayó a 62,72 % y 57,80 %, respectivamente.

2. Datos públicos y particiones

Usamos las 2.188 fotografías de *rps-cv-data-science*, de DrGFreeman, bajo CC BY-SA 4.0. Los conteos siguientes provienen de los archivos descargados; difieren ligeramente de los conteos por clase del README de origen. Reservamos además 372 imágenes CGI de Laurence Moroney, CC BY 2.0, para una evaluación externa que no intervino en entrenamiento ni selección.

Clase	Entrenamiento	Validación	Prueba	Total real
Papel	427	142	143	712
Piedra	437	145	144	726
Tijera	450	150	150	750
Total	1314	437	437	2188

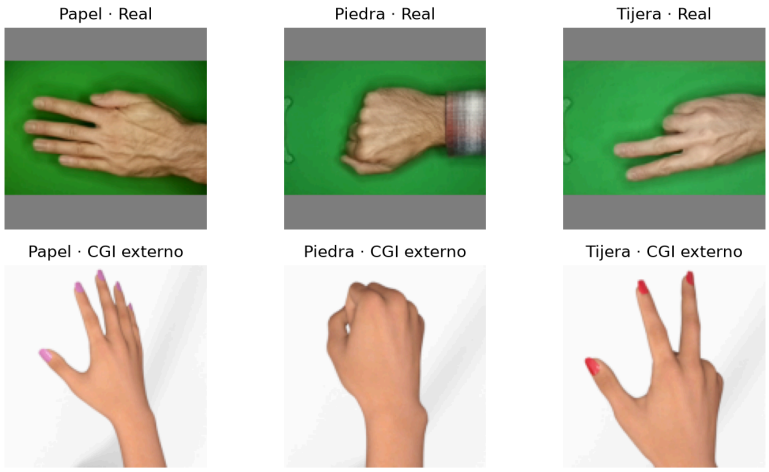


Figura 1. Arriba: fotografías de DrGFreeman. Abajo: imágenes CGI de Moroney. El cambio incluye orientación, fondo y textura. Adaptación: redimensionamiento y relleno; licencias indicadas en el texto.

Control de fuga de información

Revisamos archivos, píxeles y semejanza visual. Agrupamos tres pares con correlación ≥ 0,985 y distancia dHash ≤ 4; quedaron 2.185 grupos y ninguna exclusión. Aplicamos `StratifiedGroupKFold` de 10 pliegues, semilla 42: seis para entrenamiento, dos para validación y dos para prueba. Verificamos que no hubiera grupos ni píxeles idénticos compartidos. No existen identificadores de persona o sesión: este control reduce fugas visuales, pero no demuestra independencia entre sujetos.

Arquitectura y estrategia de entrenamiento

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12

3. Preparación y aumentación

Convertimos BGR a RGB y conservamos la proporción mediante *letterbox* a 128 × 128, con interpolación AREA y relleno 127. La entrada tiene forma (N, 128, 128, 3). El modelo transforma x en x/127,5 – 1, rango esperado por MobileNetV2. Solo aumentamos entrenamiento, antes de esta normalización.

Transformación aleatoria	Rango	Justificación
Volteo horizontal	Probabilidad 0,5	La clase no depende de la mano u orientación lateral.
Rotación y traslación	±18°; ±5 % por eje	Variación moderada de posición sin cambiar el gesto.
Zoom	±10 %	Tolerancia a distancia; evitar recortes extremos.
Contraste y brillo	Factor 0,85-1,15; ±25,5 niveles	Variación de iluminación; conserva dedos y silueta.

4. Transferencia y ajuste fino parcial

Usamos MobileNetV2 con pesos ImageNet, α = 0,35 y sin su clasificador original (Sandler et al., 2018; Keras, s. f.). Sus convoluciones separables y bloques residuales invertidos reducen el costo. La salida de la base es 4 × 4 × 1.280. Agregamos promedio espacial global, dropout 0,2 y una capa de tres logits.

$$z_c = (1/16)\,\Sigma_{h,w}\,F_{h,w,c};\quad p = \mathrm{softmax}(Wz + b);\quad L = -(1/N)\,\Sigma_i \log p_{i,y_i}$$

El promedio global evita una cabeza densa sobre 20.480 valores. La nueva capa tiene 1.280 × 3 + 3 = **3.843 parámetros**; el modelo completo tiene 414.051. Adam minimiza entropía cruzada categórica dispersa `from_logits=True`.

Etapa	Capas entrenables	Parámetros	LR / máximo de épocas
Referencia congelada	Solo cabeza	3.843	10^{-3} / 10
Ajuste fino	Desde block_13_expand y cabeza; BN congeladas	306.611	10^{-4} / 12

Primero estabilizamos la cabeza; después adaptamos los bloques superiores, preservando los filtros iniciales. Reducimos diez veces la tasa para limitar cambios bruscos en pesos útiles. Recompilamos al descongelar. La base se llama con `training=False` para conservar estadísticas de BatchNormalization, como recomienda TensorFlow; esto no impide actualizar las convoluciones habilitadas.

Protocolo de selección

Fijamos lotes de 32 y semillas 42, 7 y 2026. Cada etapa restaura la mejor pérdida de validación, con paciencia 4 y mejora mínima 10^{-4}. Elegimos el ajuste fino porque su F1 macro medio de validación supera en más de 0,001 al de la referencia: 1,0000 frente a 0,99845. La decisión quedó guardada antes de evaluar prueba y CGI. La semilla 42 se fijó para ejemplos, sin seleccionarla por prueba.

Control verificable: la base congelada no cambió; en ajuste fino cambió el kernel de block_13_expand y quedaron cero capas BatchNormalization entrenables. El archivo `control_finetuning_s42.json` registra un cambio L2 de 0,10944.

Resultados y evaluación multiclase

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12

5. Comparación controlada

Reportamos media ± desviación estándar entre tres semillas; no son intervalos de confianza ni un ensamble. Las particiones, la cabeza y la aumentación son comunes. El ajuste fino continúa la referencia y añade entrenamiento; comparamos estrategias de adaptación, no dos presupuestos iguales.

Conjunto	Etapa	Exactitud (%)	F1 macro
Validación	Congelada	99.85 ± 0.13	0.9985 ± 0.0013
Validación	Ajuste fino	100.00 ± 0.00	1.0000 ± 0.0000
Prueba real	Congelada	100.00 ± 0.00	1.0000 ± 0.0000
Prueba real	Ajuste fino	100.00 ± 0.00	1.0000 ± 0.0000
CGI externo	Congelada	62.72 ± 2.76	0.5190 ± 0.0371
CGI externo	Ajuste fino	57.80 ± 6.08	0.4743 ± 0.0439

La clase mayoritaria de entrenamiento es tijera: predecirla siempre obtiene 34,32 % de exactitud y F1 macro 0,1704 en prueba. La transferencia mejora ampliamente esta referencia trivial. El ajuste fino solo agrega 0,15 puntos porcentuales en validación y **0,00 en prueba**; por tanto, no podemos atribuirle una mejora del desempeño final en el dominio real.

6. Precision, recall y F1 por clase

Dominio	Clase	n	Precision	Recall	F1
Real	Papel	143	1.000	1.000	1.000
Real	Piedra	144	1.000	1.000	1.000
Real	Tijera	150	1.000	1.000	1.000
CGI	Papel	124	0.478	0.989	0.641
CGI	Piedra	124	0.866	0.745	0.782
CGI	Tijera	124	0.000	0.000	0.000

Promedio por clase entre semillas, sin sumar soportes. En prueba real, precision, recall y F1 macro y ponderados son 1,000. En CGI, las clases tienen el mismo soporte: el promedio macro coincide con el ponderado. La precisión macro del ajuste fino es 0,448; recall macro, 0,578; F1 macro, 0,474.

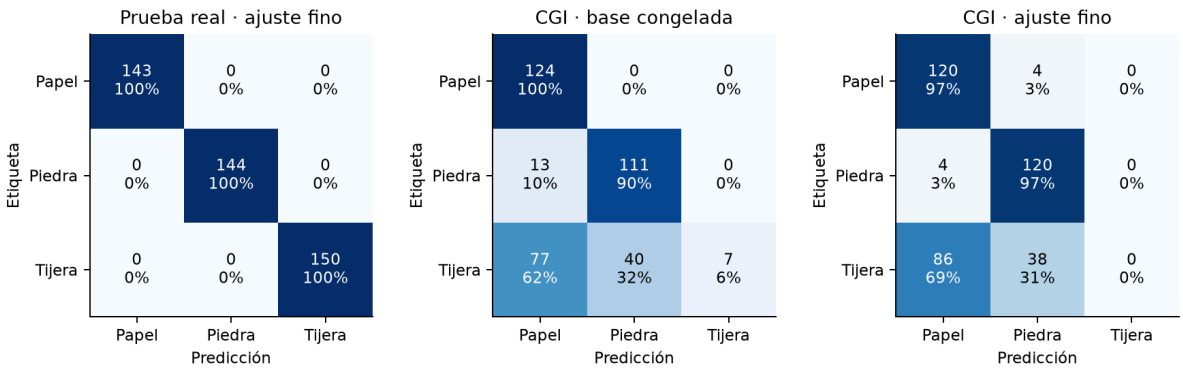


Figura 2. Conteos y porcentajes por etiqueta real; semilla 42. Las matrices CGI permiten localizar el fallo que una exactitud agregada oculta.

El ajuste fino no recupera ninguna tijera CGI en las tres semillas; la referencia alcanza recall 0,035. Ambos modelos son sensibles al cambio de dominio.

Convergencia, errores y límites de generalización

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12

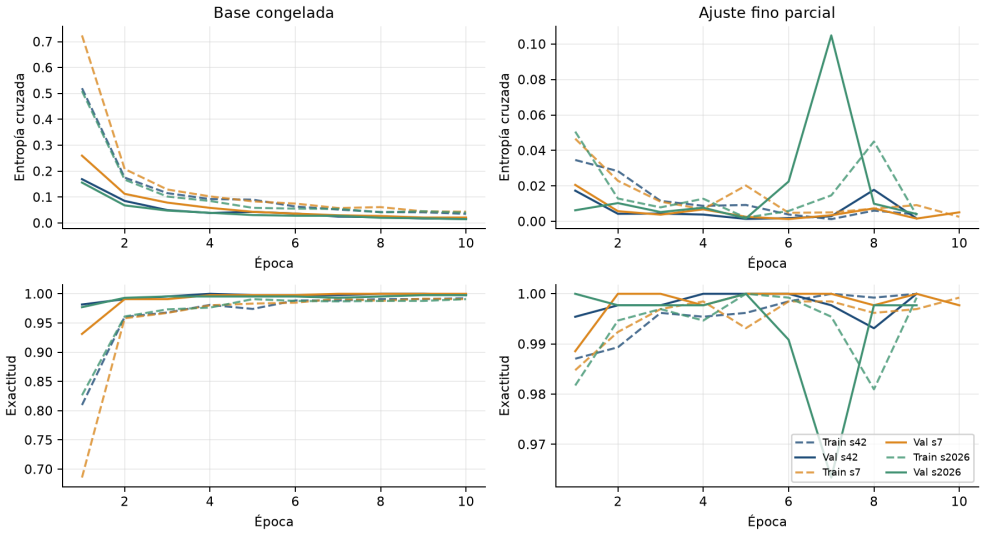


Figura 3. Líneas discontinuas: entrenamiento con aumentación y dropout; continuas: validación sin ambos. Cada color corresponde a una semilla. Los ejes de exactitud tienen distintas escalas entre etapas.

La referencia converge rápido y termina con pérdidas de validación bajas. En ajuste fino aparecen oscilaciones, especialmente con semilla 2026; restaurar el mejor punto evita conservar la caída tardía. La pérdida de entrenamiento puede ser mayor porque incluye imágenes transformadas y dropout. Una brecha pequeña dentro de este dominio no prueba generalización a otros fondos.

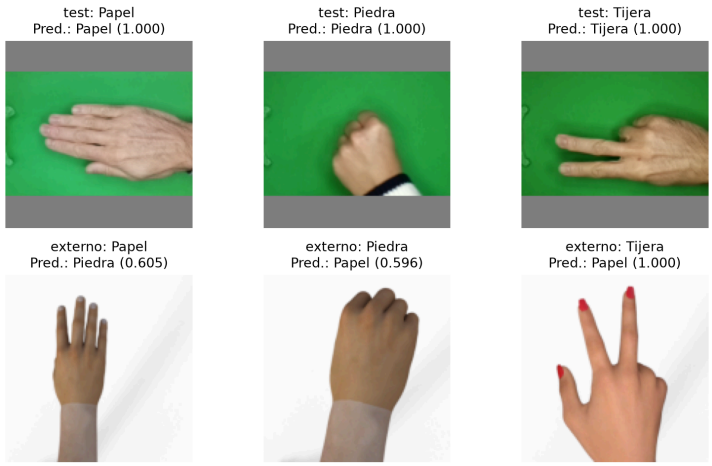


Figura 4. Aciertos reales y errores CGI del ajuste fino, semilla 42. Mostramos por clase ejemplos de mayor confianza dentro de cada condición; no son una muestra aleatoria. Imágenes adaptadas de las fuentes y licencias de la página 1.

La tijera sintética se confunde con papel incluso con confianza redondeada a 1,000. La orientación vertical, el fondo blanco y la textura sintética son cambios simultáneos; no aislamos cuál causa el error. Las rotaciones de ±18° del entrenamiento no cubren un giro de 90°. Estos ejemplos muestran que una confianza alta no equivale a una predicción fiable fuera del dominio.

Para 437/437, Wilson da un IC 95 % orientativo de [99,13 %; 100 %], suponiendo imágenes independientes. Como no conocemos sujetos o sesiones, puede ser optimista. Un bootstrap pareado de 2.000 réplicas sobre 12 grupos de secuencia CGI sitúa la diferencia ajuste fino – congelada en –4,93 puntos, IC [–11,74; 0,99]. El intervalo incluye cero y los grupos no representan personas independientes.

Reproducibilidad y conclusiones

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12

7. Registro de ejecución

Ejecutamos en CPU de un Mac M4 Pro de 12 núcleos y 24 GB: Python 3.12.11, TensorFlow 2.21.0, Keras 3.15.1 y NumPy 2.5.3. Conservamos seis modelos, predicciones por imagen, manifiestos, curvas e historiales. Los tiempos siguientes corresponden a `fit`, sin descarga, preparación ni evaluación.

Semilla	Etapa	Épocas ejecutadas	Mejor época	Tiempo (s)
42	Congelada	10	10	23.81
42	Ajuste fino	9	5	24.02
7	Congelada	10	9	23.33
7	Ajuste fino	10	6	26.78
2026	Congelada	10	10	26.08
2026	Ajuste fino	9	5	25.32

El notebook `A3_transferencia_gestos_rps.ipynb` reconstruye tablas y comprueba los archivos. El código completo está en `src/`. Desde la carpeta que contiene `src/`, el entrenamiento se reproduce con el entorno descrito en `requirements_u3.txt`:

```
python src/descargar_datos.py
python src/preparar_datos.py
python src/preparar_pesos.py
python src/entrenar_a3.py --force
python src/analizar_a3.py
```

El modo normal del notebook usa los modelos guardados; REENTRENAR=True vuelve a ajustar las seis redes. El manifiesto tiene SHA-256 `140bd2295f70727ee…`; el valor completo y las versiones están en `resultados/config_A3.json`. Conservamos las atribuciones en `recursos_y_licencias.md`.

8. Conclusiones

La transferencia permite resolver este conjunto con una cabeza pequeña. El ajuste fino está implementado y verificado, pero su ventaja de validación no se traduce en una mejora de prueba. En este caso, actualizar más capas no mejoró la clasificación del conjunto de prueba. Para un uso con fondos u orientaciones distintas necesitamos nuevas fotografías representativas, particiones por persona y una prueba externa real. Las imágenes CGI sirven como prueba de estrés, no como sustituto de esa evaluación.

Referencias

DrGFreeman. (s. f.). *Rock-Paper-Scissors image dataset* [Conjunto de datos]. GitHub. https://github.com/DrGFreeman/rps-cv-data-science

Moroney, L. (s. f.). *Datasets: Rock, Paper, Scissors* [Conjunto de datos]. https://laurencemoroney.com/datasets.html

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. *Proceedings of CVPR*, 4510-4520. https://openaccess.thecvf.com/content_cvpr_2018/html/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.html

TensorFlow. (s. f.). *Transfer learning and fine-tuning*. https://www.tensorflow.org/tutorials/images/transfer_learning

PyTorch Contributors. (s. f.). *Transfer learning for computer vision tutorial*. https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

Keras. (s. f.). *MobileNet, MobileNetV2, and MobileNetV3*. https://keras.io/api/applications/mobilenet/