Pronóstico a 10 minutos de la actividad de Internet en Milán con redes recurrentes: comparación controlada con líneas base

David Santiago Iriarte Zamora y Jose Adrian Trochez Cuellar · Grupo 12 · Técnicas Avanzadas de Modelado en IA

Repositorio: github.com/dsiriarte/Tecnicas-Avanzadas-de-Modelado-en-IA/tree/main/Unidad 4. Contiene el notebook ejecutado, los datos agregados, los pesos entrenados, el registro MLflow, las dependencias y las instrucciones de ejecución.

Resumen. Pronosticamos la actividad de Internet de Milán en el siguiente intervalo de 10 minutos con datos del Telecom Italia Big Data Challenge: 39 millones de registros de la semana del 4 al 10 de noviembre de 2013, agregados en 1.008 intervalos. Con una partición cronológica fija comparamos 147 redes LSTM y GRU, entrenadas en tres rondas de experimentos con tres semillas, frente a cinco líneas base. En la primera versión, la red predecía el nivel de la serie y no superó a la persistencia en prueba (MAE 9.906 frente a 9.230). Cambiamos el objetivo para que la red prediga el cambio respecto al último valor, agregamos la hora del día como entrada y ajustamos de forma sistemática la tasa de aprendizaje, el *dropout* y el optimizador. La GRU elegida en validación obtuvo en prueba un MAE de 5.835: 36,8 % menos que la persistencia (IC 95 % [–5.503; –902]; Diebold-Mariano, $p < 0{,}001$) y 12,7 % menos que una regresión Ridge con las mismas entradas ($p < 0{,}001$). Frente a la deriva, que repite el último cambio, la mejora de 12,8 % no es significativa ($p = 0{,}06$). La red gana sobre todo cuando la actividad sube o baja de forma sostenida, y sobrestima la actividad del domingo porque solo vio días laborales al entrenar.

Palabras clave: series de tiempo, GRU, LSTM, pronóstico de tráfico móvil, líneas base, Diebold-Mariano, reproducibilidad.

1. Introducción

Los operadores de telefonía móvil ajustan la capacidad de la red, programan mantenimientos y encienden o apagan recursos de radio según la demanda esperada. Un buen pronóstico de corto plazo ayuda a anticipar picos y a detectar fallas, porque una caída inesperada frente a lo previsto puede indicar un problema. El horizonte de 10 minutos es difícil para un modelo complejo: en ese lapso la serie cambia poco, y repetir el último valor (persistencia) ya da un pronóstico bastante bueno.

Pregunta de investigación. ¿Una red recurrente (LSTM o GRU) reduce el error de pronóstico a 10 minutos de la actividad de Internet de Milán frente a líneas base sencillas, evaluadas sobre la misma partición cronológica?

Hipótesis. La red puede aprovechar dos regularidades que la persistencia ignora: la inercia de la serie y su relación con la hora del día. Contrastamos esta hipótesis con una prueba estadística.

Las redes recurrentes procesan una secuencia paso a paso y mantienen un estado interno que resume lo visto (Goodfellow et al., 2016, cap. 10). La LSTM controla ese estado con compuertas de entrada, olvido y salida; la GRU usa solo compuertas de actualización y reinicio, y por eso tiene menos parámetros. Las dos son adecuadas para ventanas cortas de una serie con dependencia temporal fuerte.

2. Datos

Fuente y licencia. Usamos el conjunto *SMS, Call, Internet - MI* del Telecom Italia Big Data Challenge (Barlacchi et al., 2015), publicado con licencia Open Database License (ODbL). Divide Milán en una cuadrícula de 10.000 celdas y registra cada 10 minutos, por celda y por código de país, la actividad de SMS, llamadas e Internet. La ficha de datos completa está en el anexo B.

Agregación y auditoría. Los siete archivos diarios (4 al 10 de noviembre de 2013) suman 39.015.462 filas, y el 49,7 % no tiene valor en la columna `internet`. Para cada marca de 10 minutos sumamos esa columna en todas las celdas y países (`internet_sum`) y contamos los registros con valor (`observations`). No reemplazamos los vacíos por cero, porque una fila sin valor no significa que no hubo tráfico. La serie resultante tiene 1.008 intervalos sin huecos, desde las 00:00

del lunes 4 hasta las 23:50 del domingo 10, en hora local (UTC+1). `internet_sum` es un índice de actividad definido por el proveedor; no mide bytes ni usuarios.

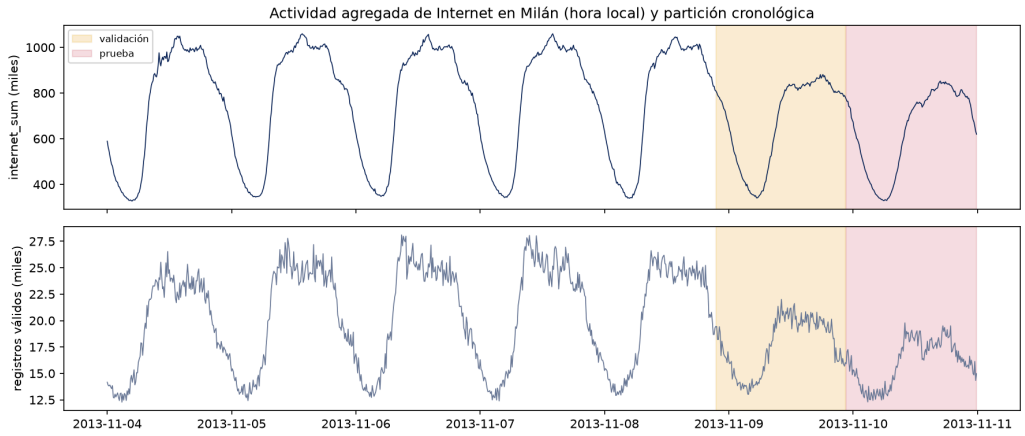


Figura 1. Actividad agregada y registros válidos por intervalo, en hora local. Amarillo: validación (sábado). Rojo: prueba (domingo).

Exploración. La serie tiene un ciclo diario claro, con un mínimo cercano a 330 mil en la madrugada, un máximo de 1,06 millones y una mediana de 806 mil. El cambio entre intervalos seguidos es pequeño (mediana de $|\Delta y| = 8.462$) y persistente: su autocorrelación en el rezago 1 es 0,67, es decir, cuando la actividad sube suele seguir subiendo. La actividad está muy correlacionada con la cobertura ($r = 0,88$), así que el índice también refleja cuántas celdas reportan datos en cada intervalo. El fin de semana hay menos actividad: el nivel medio es 771 mil en días laborales, 680 mil el sábado y 642 mil el domingo.

3. Metodología

3.1 Partición y control de fuga de información

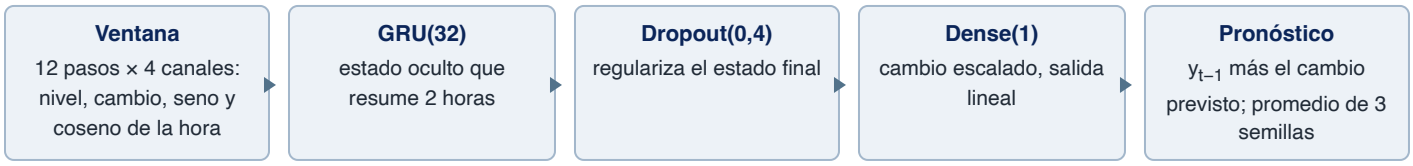
Partimos la serie en orden cronológico (70/15/15), con cortes en los intervalos 705 y 856, los mismos del avance. Con ventanas de 12 pasos (2 horas) quedan 693 ventanas de entrenamiento (lunes 02:00 a viernes 21:20), 151 de validación (viernes 21:30 a sábado 22:30) y 152 de prueba (sábado 22:40 a domingo 23:50). Una ventana puede usar observaciones anteriores al corte, pero ningún objetivo aparece en dos particiones, y un `assert` del notebook lo verifica. Los dos escaladores (nivel y cambio) se ajustan solo con datos de entrenamiento. No usamos validación cruzada con mezcla aleatoria, porque con series de tiempo eso deja pasar información del futuro al entrenamiento (Scikit-learn Developers, s. f.).

3.2 Líneas base

Evaluamos todas las líneas base sobre las mismas ventanas:

- **Persistencia:** $\hat{y}_t = y_{t-1}$. Es la línea base del avance.
- **Deriva:** $\hat{y}_t = y_{t-1} + (y_{t-1} - y_{t-2})$. Repite el último cambio.
- **Media de ventana:** promedio de las 12 observaciones anteriores.
- **Ingenuo diario:** $\hat{y}_t = y_{t-144}$, el valor del mismo instante del día anterior.
- **Ridge:** modelo lineal con las mismas entradas y el mismo objetivo que la red final; α se elige en validación ($\alpha = 100$). Sirve para separar lo que aporta el cambio de objetivo de lo que aporta la red.

3.3 Arquitectura



La red final tiene 3.681 parámetros (3.648 en la GRU y 33 en la capa de salida), unos 5 por ventana de entrenamiento. Usamos pocas unidades porque el conjunto de datos es pequeño. La hora se codifica con seno y coseno para que 23:50 y 00:00 queden cerca. La red predice el cambio y no el nivel, porque la desviación del cambio es 15 veces menor (16.524 frente a 251.097); con este objetivo, la persistencia equivale a predecir un cambio de cero. Entrenamos con la pérdida MSE y reportamos el MAE, que se expresa en las mismas unidades de la serie y es menos sensible que el RMSE a picos aislados. Todas las redes tienen el mismo presupuesto: hasta 150 épocas, lote de 32, `EarlyStopping` (paciencia 15, recupera los mejores pesos) y `ReduceLROnPlateau` (factor 0,5, paciencia 6) sobre la pérdida de validación.

3.4 Diseño experimental

Seguimos el enfoque científico de ajuste de Google Developers (s. f.). La celda (LSTM o GRU) y el objetivo son los factores **científicos**, es decir, los que queremos comparar. La tasa de aprendizaje, el *dropout* y el optimizador son factores **de ruido**: los ajustamos para cada celda antes de compararlas, para no favorecer a ninguna con una mala elección de hiperparámetros.

- **Ronda 1 (5 configuraciones).** Repite los experimentos del avance, con objetivo de nivel. A partir de E1 cambia un solo factor en cada caso: tasa de aprendizaje (E2), *dropout* (E3), celda (E4) y optimizador (E5).
- **Ronda 2 (factorial 2 × 2 × 2).** Celda {LSTM, GRU} × objetivo {nivel, cambio} × entrada {nivel; nivel, cambio y hora}, con Adam, lr = 0,001 y *dropout* = 0,2.
- **Ronda 3 (malla completa de 36 configuraciones).** lr {0,0003; 0,001; 0,003} × *dropout* {0; 0,2; 0,4} × optimizador {Adam, RMSprop} × celda {LSTM, GRU}, con el mejor objetivo y las mejores entradas de la ronda 2.

Cada configuración se entrena con las semillas 42, 7 y 2026 y con `enable_op_determinism`. La regla de selección se fijó antes de entrenar: gana el menor MAE medio de validación. MLflow Tracking (MLflow Project, s. f.) guarda cada corrida con sus parámetros, métricas, pérdidas por época y artefactos, y `salidas/experimentos.csv` conserva una copia.

3.5 Evaluación y contraste estadístico

Evaluamos la prueba una sola vez, con la configuración ya fija, y reportamos MAE, RMSE, MAPE y sesgo. Para comparar dos modelos usamos la diferencia del error absoluto en cada ventana, $d_t = |e_{red,t}| - |e_{base,t}|$, cuyo promedio es la diferencia de MAE. Calculamos su IC 95 % con *bootstrap* de bloques móviles (bloques de 12 pasos, 5.000 réplicas), que respeta la autocorrelación de los errores. También aplicamos la prueba de Diebold y Mariano (1995), $DM = \bar{d} / \sqrt{(\hat{V}_{NW}/n)}$, con varianza de Newey-West de 5 rezagos y la corrección de Harvey, Leybourne y Newbold para muestras pequeñas. Solo afirmamos que un modelo es mejor si el intervalo excluye el cero y $p < 0{,}05$.

3.6 Ciclo de vida y trazabilidad

Fase	Qué hicimos	Evidencia en el repositorio
Problema y datos	Definimos el horizonte (10 min), la variable y el alcance; auditamos los 7 archivos y agregamos la serie.	`datos/milan_data_audit.json`, CSV con SHA-256
Línea base	Persistencia como referencia; después deriva, media de ventana, ingenuo diario y Ridge sobre las mismas ventanas.	Notebook, sección 3
Primera versión (avance)	LSTM y GRU con objetivo de nivel, una semilla y cinco configuraciones. En prueba, E5 tuvo MAE 9.906, peor que la persistencia.	Notebook, sección 5 (ronda 1)
Diagnóstico	En validación, tres de cinco redes quedaron peor que la persistencia y los resultados variaban mucho entre semillas.	Notebook, sección 5
Segunda versión	Ronda 2 (objetivo y entradas) y ronda 3 (malla de 36 configuraciones), con tres semillas y selección en validación.	`mlruns/`, `salidas/experimentos.csv`
Evaluación	Una evaluación en prueba, contrastes pareados, análisis de errores y costos.	`salidas/comparacion_prueba.csv`, `contrastes_prueba.csv`

Fase	Qué hicimos	Evidencia en el repositorio
Cierre	Pesos, metadatos, fichas del modelo y de los datos, dependencias y verificación al recargar los pesos.	`modelos/`, anexos A y B, `requirements_u4.txt`

4. Resultados

4.1 Experimentos en validación

Ronda y factor	Configuración	MAE val.	DE	vs. persistencia
Líneas base en validación: persistencia 9.147 · deriva 7.612 · Ridge 5.875 · media de ventana 48.485 · ingenuo diario 100.813				
R1 · referencia	E1 LSTM, Adam, lr 0,001, p 0,2 (nivel)	10.703	1.682	+17,0 %
R1 · solo lr	E2 lr 0,0005	12.194	1.209	+33,3 %
R1 · solo *dropout*	E3 p 0,3	10.669	730	+16,6 %
R1 · solo celda	E4 GRU	6.727	740	–26,5 %
R1 · solo optimizador	E5 RMSprop	7.484	581	–18,2 %
R2 · objetivo	GRU, cambio, entrada nivel	6.366	51	–30,4 %
R2 · objetivo y entradas	GRU, cambio, nivel + cambio + hora	5.844	299	–36,1 %
R2 · solo entradas	GRU, nivel, nivel + cambio + hora	30.153	10.888	+229,7 %
R3 · mejor LSTM	Adam, lr 0,0003, p 0	5.780	280	–36,8 %
R3 · mejor GRU (seleccionada)	**Adam, lr 0,003, p 0,4**	**5.653**	**148**	**–38,2 %**

Tabla 1. MAE de validación (media de 3 semillas) y desviación estándar entre semillas.

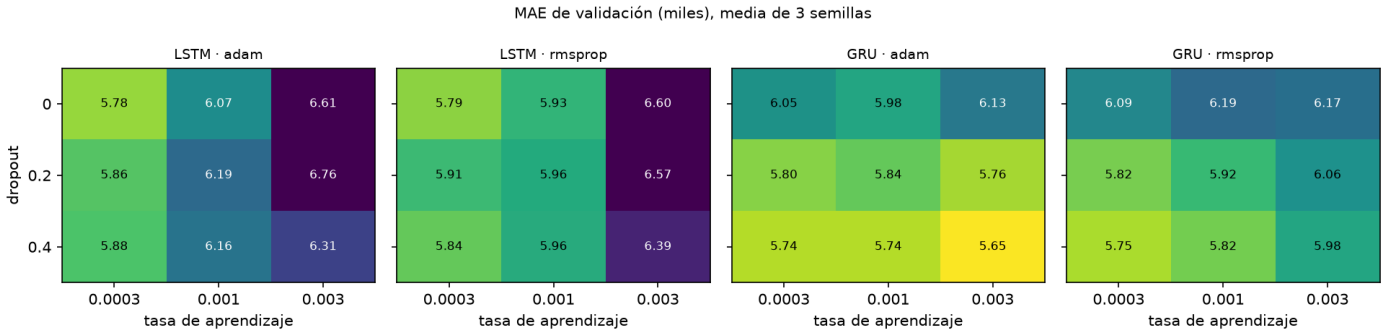


Figura 2. Ronda 3: MAE de validación (miles) para cada combinación de tasa de aprendizaje y *dropout*.

En la ronda 3, el MAE medio fue 5.861, 5.981 y 6.249 con tasas de aprendizaje de 0,0003, 0,001 y 0,003; 6.117, 6.038 y 5.937 con *dropout* de 0, 0,2 y 0,4; 6.018 con Adam y 6.043 con RMSprop; y 5.918 con GRU frente a 6.143 con LSTM. Las cinco mejores configuraciones quedaron entre 5.653 y 5.760. Al promediar las tres semillas de la configuración elegida, el MAE de validación bajó de 5.653 a 5.599, así que adoptamos ese promedio como modelo final.

4.2 Curvas de aprendizaje

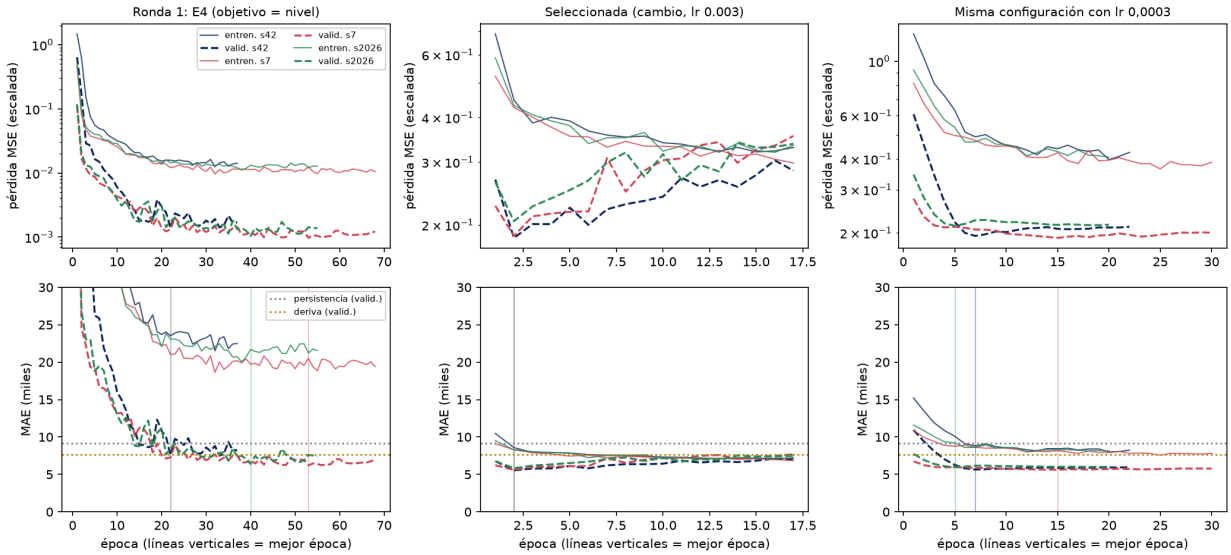


Figura 3. Pérdida MSE escalada (arriba, escala logarítmica) y MAE en unidades originales (abajo) por época. Línea continua: entrenamiento; discontinua: validación; una línea por semilla. Las líneas punteadas horizontales son la persistencia y la deriva en validación, y las verticales marcan la mejor época.

Con el objetivo de nivel (E4), la pérdida de entrenamiento queda unas 12 veces por encima de la de validación. La mejor época varía entre 22 y 53 según la semilla, y la tasa de aprendizaje termina entre 1,6e-05 y 1,3e-04. Con el objetivo de cambio, la pérdida de validación llega a su mínimo en la época 2 con las tres semillas; luego la de entrenamiento sigue bajando y la de validación sube, hasta que el entrenamiento se detiene en la época 17. La pérdida de validación queda por debajo de la de entrenamiento (cociente 0,41-0,47). La varianza del cambio real en validación es el 48 % de la de entrenamiento (desviación de 11.433 frente a 16.505). Medido sin *dropout* y con los pesos recuperados, el R^2 del cambio de la GRU es 0,64 en entrenamiento y 0,60 en validación; el de E4 es 0,30 y 0,45. Con lr = 0,0003, la misma red llega a su mínimo entre las épocas 5 y 15 y obtiene un MAE de 5.744.

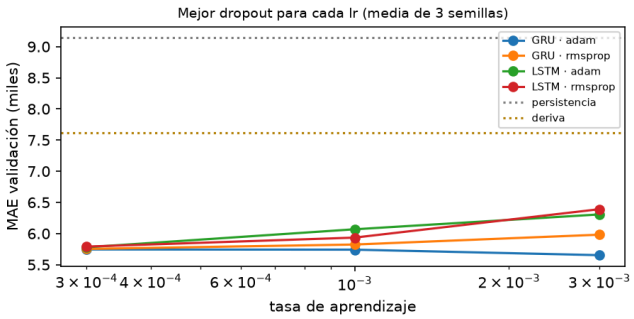


Figura 4. Sensibilidad a la tasa de aprendizaje: mejor MAE de validación por celda y optimizador (media de 3 semillas).

4.3 Comparación en prueba

Modelo (domingo)	MAE	RMSE	MAPE	vs. persist.
Persistencia	9.230	11.584	1,6 %	—
Deriva	6.687	8.944	1,0 %	–27,5 %
Media de ventana	48.978	60.887	8,7 %	+430,6 %
Ingenuo diario	44.226	58.200	7,5 %	+379,2 %
Ridge (cambio)	6.687	8.306	1,1 %	–27,6 %
Avance: E5 LSTM (nivel)	9.906	12.882	—	+7,3 %
R1: E4 GRU (nivel)	7.370	10.194	1,1 %	–20,2 %
Mejor LSTM (R3)	6.022	7.667	1,0 %	–34,8 %
GRU seleccionada	**5.835**	**7.364**	**1,0 %**	**–36,8 %**

GRU frente a	ΔMAE	IC 95 %	p (DM)	gana
Persistencia	**–3.395**	**[–5.503; –902]**	**< 0,001**	**69 %**
Ridge (cambio)	–852	[–1.453; –508]	< 0,001	70 %
Deriva	–853	[–1.687; +205]	0,06	52 %
E4 de la ronda 1	–1.535	[–3.233; +40]	0,05	55 %

Tabla 2 (izquierda). Métricas en las 152 ventanas de prueba. La fila del avance viene de su notebook original (una semilla y otro protocolo de entrenamiento). Tabla 3 (derecha). Contrastes pareados; «gana» es el porcentaje de ventanas en que la GRU tiene menor error absoluto. Las tres semillas de la GRU dan MAE de 5.560, 5.645 y 6.420 (5.875 ± 474).

4.4 Errores

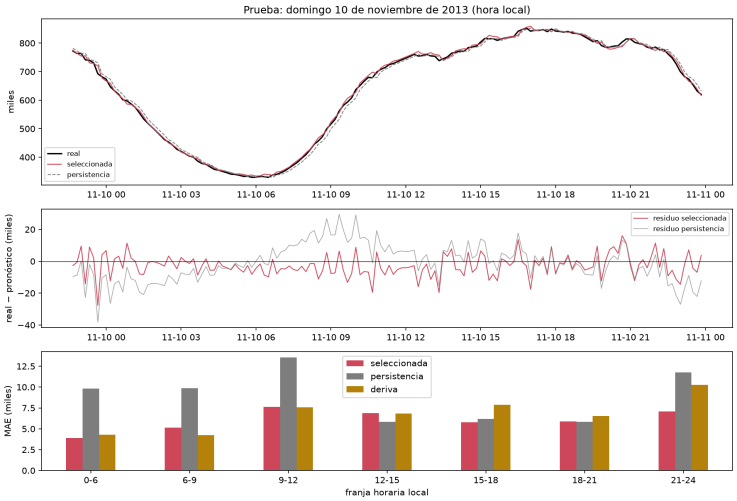


Figura 5. Prueba: serie real, GRU y persistencia (arriba), residuos (centro) y MAE por franja horaria local (abajo).

Subgrupo de prueba	GRU	Persistencia	Deriva
Tercil estable del cambio real	5.213	2.514	5.674
Tercil medio	5.180	7.935	6.258
Tercil de rampa	7.098	17.215	8.121
Madrugada, 0-6 h	3.883	9.815	4.303
Mediodía, 12-15 h	6.899	5.841	6.827
Noche, 21-24 h	7.058	11.784	10.260

Tabla 4. MAE por subgrupo. Sesgo medio (real – pronóstico): GRU –2.633; persistencia –1.066. Percentil 95 del error absoluto: 13.872 frente a 21.839. Ljung-Box sobre los residuos de la GRU: p = 0,79, 0,28 y 0,21 en los rezagos 1, 6 y 12. Correlación entre el error absoluto y la cobertura: 0,19.

5. Interpretación

5.1 El objetivo de la red importó más que la arquitectura

Con el objetivo de nivel, tres de las cinco configuraciones del avance quedaron peor que la persistencia en validación, y la desviación entre semillas llegó a 1.682. Para acertar un cambio cercano a 8 mil, la red tenía que reproducir un valor de unos 800 mil, y cualquier error en el nivel pesaba más que el cambio mismo. Las curvas lo muestran: el

dropout altera un estado que representa ese nivel, y la pérdida de entrenamiento queda 12 veces por encima de la de validación. Cuando la red predice el cambio, parte de la persistencia y solo aprende la corrección. Por eso mejoran todas las celdas y la desviación entre semillas baja a 51-120.

5.2 La hora del día ayuda solo con el objetivo de cambio

Con el objetivo de nivel, la red aprende el perfil de lunes a viernes y falla el sábado, que tiene otro nivel (MAE 30.153). Con el objetivo de cambio, aprende a qué horas suele subir o bajar la actividad. Esa regularidad se mantiene mejor de un día a otro, y el MAE baja de 6.366 a 5.844.

5.3 La regularización pesa más que el optimizador

Con 693 ventanas, el principal riesgo es el sobreajuste. El error bajó al subir el *dropout*, Ridge eligió el α más alto y la pérdida de validación llegó a su mínimo en la época 2. Interpretamos esa época temprana como un sobreajuste rápido que la parada temprana controla, y no como falta de entrenamiento, por dos razones. Primero, después de la época 2 la pérdida de validación sube mientras la de entrenamiento baja. Segundo, la diferencia entre ambas curvas se explica por el *dropout* y por la menor varianza del cambio en validación (cociente 0,48): sin *dropout*, el R^2 del cambio es casi igual en las dos particiones (0,64 y 0,60). La versión con lr = 0,0003 llega al mismo error con curvas más suaves, y las cinco mejores configuraciones están dentro de la variación entre semillas. Lo que se mantiene es la combinación GRU, *dropout* 0,4 y objetivo de cambio, más que un valor exacto de la tasa.

5.4 Qué está demostrado y qué no

La mejora frente a la persistencia (–36,8 %) es grande, se repite con las tres semillas y es significativa. Frente a Ridge, la ventaja de 12,7 % muestra que la parte no lineal de la red aporta algo más que el cambio de objetivo. Frente a la deriva, en cambio, la mejora de 12,8 % no es significativa con un solo día de prueba: la red gana en el 52 % de las ventanas y pierde cuando la serie está estable. La deriva, sin entrenamiento, ya logra la mayor parte de la mejora sobre la persistencia (–27,5 %), y la red agrega unos 9 puntos porcentuales más. El MAE de validación (5.599) y el de prueba (5.835) difieren en 4 %, así que la selección no quedó ajustada a la validación.

5.5 Por qué se equivoca la red

La red gana cuando la actividad sube o baja de forma sostenida (madrugada y caída nocturna) y pierde cuando la serie está estable, porque ahí la persistencia acierta casi siempre. El sesgo negativo del domingo tiene una explicación directa: el modelo solo vio días laborales y el domingo tiene 17 % menos actividad. Los residuos no tienen autocorrelación, así que lo que falta no está en la ventana de 2 horas sino en variables que el modelo no recibe, como el día de la semana o la cobertura.

6. Riesgos, limitaciones y consideraciones éticas

- **Validez externa.** Solo hay una semana de datos. Entrenamos con días laborales y evaluamos un sábado y un domingo, y no medimos la variación entre semanas, festivos o eventos. El resultado no debe extenderse a otros meses sin una nueva validación.
- **Incertidumbre estadística.** La prueba es un único bloque de 152 ventanas, y los intervalos reflejan la variación dentro de ese día, no entre días. El avance ya había usado la prueba una vez; ninguna decisión de esta versión la usó, pero ya no es una partición sin ver.
- **Medición.** El índice depende de la cobertura (r = 0,88) y del manejo de los valores ausentes. Si cambia el número de celdas que reportan, la serie cambia aunque la demanda sea la misma.
- **Privacidad.** Los datos vienen anonimizados y agregados por celda, y nosotros los agregamos a nivel de ciudad. El modelo no usa ni puede reconstruir información de personas. Un uso por celda exigiría revisar el riesgo de reidentificación en zonas con poca actividad.
- **Riesgo operativo.** Si el modelo sobrestima la actividad del fin de semana, se pueden mantener recursos encendidos sin necesidad; si la subestima en una subida, el servicio se puede degradar. Antes de automatizar decisiones hay que acotar los errores grandes (percentil 95 de 13.872, el 1,7 % de la mediana de la serie).

7. Recomendaciones de uso y despliegue

- **Uso previsto.** Pronóstico a 10 minutos de la actividad agregada de la ciudad, como apoyo a la planificación y como referencia para detectar anomalías. No sirve para decisiones por celda, por usuario ni de facturación.
- **Respaldo.** Mantener la deriva como respaldo automático: no tiene costo y su MAE de prueba es solo 15 % mayor (6.687 frente a 5.835). Si faltan datos en la ventana o la cobertura cae de golpe, usar esa regla.
- **Monitoreo.** Calcular cada día el MAE móvil y compararlo con el de la deriva. Si la red deja de superarla durante varios días, o si el sesgo pasa de un umbral, reentrenar.
- **Antes de producción.** Reentrenar con varias semanas que incluyan fines de semana; agregar el día de la semana y la cobertura como entradas; validar con origen móvil (`TimeSeriesSplit`) para estimar la variación entre días; y entregar intervalos de predicción, no solo un valor.

8. Conclusiones

Construimos un pipeline reproducible de pronóstico a 10 minutos con partición cronológica, escaladores sin fuga de información, cinco líneas base, 147 redes en tres rondas controladas con tres semillas y registro completo en MLflow. La primera versión, que predecía el nivel, no superó a la persistencia en prueba. El análisis en validación mostró por qué, y el cambio de objetivo resolvió el problema. La GRU final reduce el MAE de prueba en 36,8 % frente a la persistencia y en 12,7 % frente a Ridge, con significancia estadística. Frente a la deriva, la mejora de 12,8 % no es significativa con un solo día de prueba, por lo que no afirmamos que la red sea mejor que esa regla. La red aporta sobre todo cuando la actividad sube o baja con fuerza. Su principal debilidad es el sesgo del fin de semana, que solo se puede corregir con más semanas de datos y con el calendario como entrada.

9. Reproducibilidad

El repositorio contiene `notebooks/U4_pronostico_internet_milan.ipynb` (ejecutado); `datos/`, con el CSV, cuyo SHA-256 se verifica al cargarlo, y la auditoría de los archivos originales; `modelos/`, con los tres `.keras` de la GRU final y `metadatos_modelo_final.json` (configuración, escaladores, métricas y versiones); `salidas/`, con figuras y tablas; `mlruns/`, con el registro MLflow; y `requirements_u4.txt`. El notebook no usa rutas absolutas y corre completo en unos 6 minutos en CPU; en Colab, si no encuentra el CSV, lo descarga del repositorio. La última celda recarga los pesos guardados y verifica que reproducen el pronóstico reportado (diferencia máxima de 0,0000). Versiones: Python 3.12.11, TensorFlow 2.21.0, Keras 3.15.1, scikit-learn 1.9.1, pandas 3.0.5, NumPy 2.5.3 y MLflow 3.17.2.

```
python -m pip install -r requirements_u4.txt
jupyter nbconvert --to notebook --execute --inplace notebooks/U4_pronostico_internet_milan.ipynb
```

Referencias

Barlacchi, G., De Nadai, M., Larcher, R., Casella, A., Chitic, C., Torrisi, G., Antonelli, F., Vespignani, A., Pentland, A., & Lepri, B. (2015). A multi-source dataset of urban life in the city of Milan and the Province of Trentino. *Scientific Data, 2*, 150055. https://doi.org/10.1038/sdata.2015.55

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253-263. https://doi.org/10.1080/07350015.1995.10524599

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86-92. https://doi.org/10.1145/3458723

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. https://www.deeplearningbook.org/

Google Developers. (s. f.). *A scientific approach to improving model performance*. https://developers.google.com/machine-learning/guides/deep-learning-tuning-playbook/scientific

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220-229). https://research.google/pubs/model-cards-for-model-reporting/

MLflow Project. (s. f.). *MLflow Tracking*. https://mlflow.org/docs/latest/ml/tracking/

Scikit-learn Developers. (s. f.). *Cross-validation: evaluating estimator performance*. https://scikit-learn.org/stable/modules/cross_validation.html

Telecom Italia. (s. f.). *The Telecom Italia Big Data Challenge*. https://theodi.fbk.eu/openbigdata

Anexo A. Ficha del modelo

Estructura según Mitchell et al. (2019).

Detalles	Red GRU(32) seguida de Dropout(0,4) y Dense(1), con 3.681 parámetros, en TensorFlow/Keras 2.21. El pronóstico es el promedio de tres modelos entrenados con las semillas 42, 7 y 2026 (Adam, lr = 0,003, lote 32, MSE, parada temprana en la época 2). Proyecto académico del Grupo 12. Pesos: `modelos/modelo_final_GRU_semilla{42,7,2026}.keras`.
Uso previsto	Pronóstico a un paso (10 minutos) de la actividad de Internet agregada de Milán, como apoyo a la planificación y a la detección de anomalías. **Fuera de alcance:** pronósticos por celda o por usuario, horizontes largos, otras ciudades u otros periodos sin reentrenar, y decisiones automáticas sin supervisión.
Entradas y salida	Ventana de 12 pasos con el nivel y el cambio escalados (la media y la desviación de entrenamiento están en `metadatos_modelo_final.json`) y el seno y coseno de la hora local. Salida: cambio escalado; el pronóstico es y_{t-1} más ese cambio.
Factores	El desempeño cambia según el régimen (subida o bajada sostenida, o serie estable), la franja horaria y el tipo de día. Solo se evaluó en un sábado (validación) y un domingo (prueba).
Métricas	MAE (principal), RMSE, MAPE y sesgo. Comparación pareada con IC por *bootstrap* de bloques y prueba de Diebold-Mariano.
Datos de evaluación	Validación: 151 ventanas (viernes 21:30 a sábado 22:30). Prueba: 152 ventanas (sábado 22:40 a domingo 23:50).
Datos de entrenamiento	693 ventanas, de lunes 02:00 a viernes 21:20 (4 al 8 de noviembre de 2013).
Resultados	Prueba: MAE 5.835, RMSE 7.364, MAPE 1,0 %. Frente a la persistencia, –36,8 % ($p < 0{,}001$); frente a Ridge, –12,7 % ($p < 0{,}001$); frente a la deriva, –12,8 % ($p = 0{,}06$, no significativo). MAE por semilla: 5.560, 5.645 y 6.420.
Consideraciones éticas	Datos anonimizados y agregados a nivel de ciudad, sin información personal. El riesgo principal es operativo: sobrestimación en fin de semana (sesgo de –2.633) y errores grandes en las subidas y bajadas fuertes.
Advertencias	Solo hay una semana de datos y no hay evidencia de estabilidad entre semanas ni en festivos. Mantener la deriva como respaldo y reentrenar con más semanas antes de cualquier uso operativo.

Anexo B. Ficha de los datos

Estructura según Gebru et al. (2021).

Motivación	Telecom Italia publicó los datos en 2014 para el Big Data Challenge, con el fin de fomentar la investigación sobre la vida urbana a partir de datos de telecomunicaciones (Barlacchi et al., 2015).
Composición	Cuadrícula de 10.000 celdas de unos 235 × 235 m sobre Milán. Para cada celda, intervalo de 10 minutos y código de país: actividad de SMS entrantes y salientes, llamadas entrantes y salientes, e Internet. Usamos la semana del 4 al 10 de noviembre de 2013: 7 archivos diarios, 39.015.462 filas, 322 códigos de país y 144 marcas de tiempo por día.
Recolección	Registros de detalle de llamadas (CDR) de la red de Telecom Italia. La actividad es proporcional al número de eventos y el proveedor la escaló, así que no corresponde a bytes ni a usuarios.
Preprocesamiento propio	Suma de `internet` por marca de tiempo sobre todas las celdas y países, y conteo de registros con valor. El 49,7 % de las filas no tiene `internet` y no se imputa. La marca en milisegundos UTC se convierte a la hora local de Milán. Resultado: `datos/milan_internet_aggregated.csv`, 1.008 filas, SHA-256 `924333a3…1484`. La auditoría por archivo está en `datos/milan_data_audit.json`.
Calidad	Sin huecos temporales ni intervalos vacíos. La cobertura varía entre intervalos y está muy correlacionada con la actividad (r = 0,88). Solo hay una semana, con cinco días laborales y un fin de semana.
Usos	Adecuado para estudiar la dinámica de corto plazo de la actividad agregada. No es adecuado para inferir comportamientos individuales, la demanda absoluta en bytes ni patrones estacionales de largo plazo.
Distribución y licencia	Open Database License (ODbL). Nuestra serie agregada es una base de datos derivada y se distribuye con atribución a la fuente original.
Mantenimiento	El conjunto original es estático (2013). Nuestro CSV tiene versión en el repositorio, y el notebook verifica su SHA-256 antes de usarlo.